



Pós-Graduação Data Science Academy

Técnicas e Procedimentos de Carga de Dados

Técnicas e Procedimentos de Carga de Dados



A extração e carga de dados são etapas críticas sejam em projetos de Ciência de Dados, Inteligência Artificial ou áreas afins, uma vez que elas garantem o acesso a informações que serão analisadas e utilizadas para construir soluções. A seguir, descrevemos as principais técnicas e procedimentos para garantir uma execução eficiente e segura desse processo:

1. Uso de Conectores ODBC e JDBC:

A extração e carga de dados podem exigir o uso de conectores como ODBC (Open Database Connectivity) ou JDBC (Java Database Connectivity) para conectar-se a fontes e destinos de dados. Certifique-se de verificar a documentação da plataforma de origem e destino, garantindo que esses conectores sejam compatíveis. Além disso, esses processos muitas vezes exigem autenticação, como o uso de credenciais de login e senha, para garantir a segurança do acesso.

2. Conexões por Pacotes em R e Python:

Linguagens como R e Python oferecem diversos pacotes que facilitam a conexão a diferentes fontes e destinos de dados, como bancos de dados (SGBDs) e planilhas Excel. Nesses casos, é comum utilizar métodos de autenticação baseados em usuário e senha. É importante testar a conexão antes de iniciar o processo de carga para evitar interrupções ou erros durante o projeto.

3. APIs e Módulos de Conexão Personalizados:

Quando não há conectores ou pacotes prontos, pode ser necessário desenvolver APIs ou módulos personalizados para a extração e carga de dados. Essa abordagem é particularmente útil quando trabalhamos com fontes de dados proprietárias ou não convencionais. O desenvolvimento desses conectores deve ser feito de maneira segura, garantindo a integridade e confidencialidade dos dados.

4. Validação de Integridade e Escolha do Tipo de Carregamento:

Durante a extração e carga de dados, é fundamental verificar a integridade das informações, principalmente quando se trabalha com múltiplas fontes de dados. Além disso, é importante escolher o tipo adequado de carregamento, que pode ser realizado em batch (lote) ou em streaming (fluxo contínuo), dependendo das necessidades do projeto. A documentação técnica das fontes de dados é um excelente recurso para entender melhor a organização dos dados e identificar possíveis problemas.

5. Extração de Dados de Páginas Web e APIs:

Se o projeto envolve a extração de dados de sites ou APIs de redes sociais, é essencial verificar se o site permite essa atividade. Muitos sites têm um arquivo "robots.txt" que especifica as permissões para extração de dados. Além disso, todas as conexões feitas a sites são registradas nos logs dos servidores, e o acesso pode ser rastreado por meio do provedor de internet. Respeitar essas regras é fundamental para evitar penalidades legais.

6. Uso de Arquivos CSV e TXT:

Formatos como CSV e TXT são amplamente utilizados para extração e carga de dados, especialmente como etapas intermediárias do processo. Se o volume de dados for gerenciável, esses arquivos podem servir como uma alternativa prática para armazenamento temporário ou para consolidação de dados após a limpeza. Esses arquivos podem ser armazenados em Data Lakes para garantir a segurança e o fácil acesso.

7. Processo ETL e o Papel do Engenheiro de Dados:

O processo de ETL (Extração, Transformação e Carga de Dados) é frequentemente de responsabilidade do Engenheiro de Dados. No entanto, cientistas de dados devem ter um conhecimento básico desse fluxo, pois podem precisar intervir para garantir que os dados corretos estejam sendo utilizados em cada etapa do projeto. Compreender o processo ETL é fundamental para alinhar a extração e carga de dados às necessidades analíticas.

8. Anonimização de Dados Sensíveis:


A anonimização de dados sensíveis, como CPF ou números de cartão de crédito, é uma exigência legal em muitos países, conforme regulado por leis como a LGPD (Lei Geral de Proteção de Dados). Esses dados devem ser removidos ou anonimizados durante o processo de extração e carga, a menos que haja permissão explícita para o seu uso. Isso evita riscos legais e protege a privacidade dos indivíduos envolvidos.

9. Extração e Carga Contínua de Dados:

Em muitos projetos, especialmente aqueles que envolvem machine learning contínuo, é necessário extrair e carregar dados de forma regular. Por exemplo, um modelo preditivo pode requerer atualizações diárias de dados. Nesse caso, é importante automatizar o processo de carga por meio de um fluxo de ETL ou jobs programados, garantindo a consistência das informações ao longo do tempo.

10. Descarte de Dados Não Utilizados:

Dados não utilizados consomem espaço de armazenamento e recursos financeiros. É fundamental remover dados que não são mais necessários, ou, alternativamente, implementar um processo de backup antes de sua exclusão, para liberar espaço de armazenamento. Isso garante a eficiência operacional e reduz custos de infraestrutura.

**Equipe DSA**

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.