



Pós-Graduação Data Science Academy

Técnicas e Procedimentos de Limpeza de Dados



Técnicas e Procedimentos de Limpeza de Dados



A fase de limpeza de dados é uma das mais importantes em qualquer projeto seja de Ciência de Dados, IA, MLOps, Segurança, Engenharia, Análise ou áreas afins, pois garante que os dados estejam prontos para análise e modelagem. Abaixo estão as principais técnicas e procedimentos para realizar essa tarefa de forma eficaz:

1. Verificação Inicial dos Dados:

O primeiro passo é realizar uma verificação inicial para detectar problemas comuns, como valores ausentes, dados duplicados ou colunas com valores constantes. Nunca presuma que os dados estão limpos; é essencial validar e corrigir qualquer inconsistência antes de prosseguir.

2. Aplicação de Filtros:

Nem todos os dados presentes na fonte serão relevantes para o projeto. Portanto, aplique filtros para remover colunas e linhas que não agregam valor à análise. Isso simplifica o conjunto de dados e melhora a eficiência das análises posteriores.

3. Remoção de Linhas Duplicadas:

Dados duplicados podem distorcer os resultados de um projeto. Linhas que possuem valores idênticos em todas as colunas devem ser removidas para evitar o reforço indevido de certas observações. Retenha apenas uma das entradas duplicadas para garantir a precisão dos resultados.

4. Tratamento de Valores Ausentes:

Valores ausentes são comuns e precisam ser tratados adequadamente. Para variáveis numéricas, a técnica de imputação pode ser utilizada, preenchendo os valores ausentes com a média, mediana ou moda. Para variáveis categóricas, é possível substituir os valores ausentes por uma categoria existente ou por uma nova que represente a ausência de informação. Avalie cuidadosamente a estratégia de imputação para evitar viés nos resultados.

5. Formatação dos Dados:

Sempre que possível, organize os dados em formato tabular, com linhas e colunas, mesmo que a origem seja semi-estruturada ou não estruturada. Essa organização facilita o processamento, a análise e a aplicação de técnicas estatísticas e de machine learning.

6. Nomeação de Colunas:

Nomes de colunas são essenciais para a compreensão e organização dos dados. Use nomes descritivos, sem espaços ou caracteres especiais, para facilitar o uso dos dados em análises e modelos. Isso também ajuda a manter a consistência e a legibilidade do conjunto de dados.

7. Encriptação de Dados Sensíveis:

Dados sensíveis, como CPF, número de identidade ou informações bancárias, devem ser evitados ou, se necessários, devidamente encriptados. Certifique-se de que há autorização para o uso desses dados e aplique medidas de segurança adequadas para proteger a privacidade.

8. Separação de Colunas com Informações Múltiplas:


Colunas que contêm mais de uma informação, como códigos que combinam cidade, região e identificadores, devem ser separadas em múltiplas colunas. Cada coluna deve conter apenas um tipo de informação, garantindo que os dados sejam mais fáceis de manipular e interpretar.

9. Ajuste dos Tipos de Dados:

Não confie cegamente na classificação automática das ferramentas de análise (como Python, R ou Power BI). Verifique e ajuste os tipos de dados conforme necessário, garantindo que cada coluna esteja no formato correto (numérico, categórico, texto, etc.) para evitar erros durante as análises.

10. Agrupamento e Divisão por Faixas:

Em alguns casos, é mais útil agrupar os dados em categorias ou faixas. Por exemplo, ao invés de utilizar a idade exata de cada paciente, pode-se criar faixas etárias. Isso facilita a análise e pode melhorar o desempenho de modelos de machine learning, permitindo generalizações mais robustas.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.