



Pós-Graduação Data Science Academy

Técnicas e Procedimentos de Análise Estatística

Técnicas e Procedimentos de Análise Estatística



A análise estatística dos dados em projetos de Ciência de Dados e Inteligência Artificial geralmente ocorre em duas etapas principais. A primeira etapa consiste na análise exploratória, onde buscamos detectar possíveis problemas e padrões nos dados. A segunda etapa envolve o pré-processamento, no qual preparamos os dados para uso nos modelos de aprendizado. A seguir, detalhamos as técnicas e procedimentos focados na primeira etapa:

1. Análise Descritiva:

Esta é uma das técnicas mais utilizadas na análise exploratória. Seu objetivo é descrever e resumir os dados, fornecendo uma visão geral das principais características. A análise descritiva inclui o cálculo de estatísticas como média, mediana, moda, desvio padrão, entre outras. Ela permite que o cientista de dados tenha um entendimento inicial do conjunto de dados, identificando possíveis anomalias e padrões.

2. Resumo de Estatísticas:

Estatísticas como a média e mediana (para variáveis numéricas) ou a frequência (para variáveis categóricas) são ferramentas essenciais para organizar e interpretar os dados. Esses resumos ajudam a detectar anomalias, como outliers, e a entender como os dados estão distribuídos. É sempre recomendável criar resumos estatísticos detalhados antes de qualquer etapa mais complexa da análise.

3. Identificação dos Tipos de Dados:

Antes de escolher as técnicas estatísticas adequadas, é altamente recomendável identificar se as variáveis são numéricas ou categóricas. A escolha da técnica correta depende diretamente do tipo de dado com o qual se está trabalhando. Por exemplo, para variáveis numéricas, medidas como média e desvio padrão são úteis, enquanto, para variáveis categóricas, a moda e a contagem de frequência são mais apropriadas.

4. Cuidado com a Média e Outliers:

Embora a média seja uma medida comum para entender a centralidade dos dados, ela pode ser distorcida por valores extremos, ou outliers. Para evitar interpretações errôneas, é essencial considerar o desvio padrão, que indica o quanto os dados estão dispersos em relação à média. Ao analisar os dados, sempre combine a média com o desvio padrão para obter uma visão mais clara da distribuição.

5. Mediana e Moda:

A mediana é o valor central de um conjunto de dados ordenado, sendo menos suscetível a outliers do que a média. Já a moda representa o valor que mais aparece em uma variável e pode ser usada tanto para variáveis numéricas quanto categóricas. Ambas são estatísticas valiosas em cenários onde a média pode não ser a melhor medida para representar os dados.

6. Amostragem:

Quando lidamos com grandes volumes de dados, a análise completa pode ser inviável. Nesse caso, o uso de amostragem é uma técnica prática e eficiente. É importante que a amostra seja significativa e extraída de forma aleatória, garantindo que ela represente bem o conjunto de dados total.

7. Correlação:

A correlação mede a relação entre duas variáveis e varia de -1 (correlação negativa perfeita) a +1 (correlação positiva perfeita). Em projetos de Ciência de Dados, buscamos correlação alta entre variáveis preditoras (X) e a variável alvo (Y). No entanto, correlações altas entre variáveis preditoras podem indicar multicolinearidade, um problema que precisa ser corrigido removendo uma das variáveis correlacionadas.

8. Histograma e Distribuição Normal:


Histogramas são ferramentas úteis para visualizar a distribuição de variáveis numéricas. Muitos algoritmos de aprendizado de máquina assumem que os dados seguem uma distribuição normal. Um histograma com formato de sino sugere essa distribuição. Realizar um teste estatístico de normalidade ajuda a validar essa suposição e é uma etapa recomendada antes de seguir para modelos mais complexos.

9. Outliers:

Outliers são valores extremos, geralmente definidos como sendo três desvios-padrão acima ou abaixo da média. Esses pontos podem indicar erros ou anomalias nos dados, mas, em alguns casos, podem representar informações importantes para o projeto. Dependendo do contexto, os outliers podem ser removidos ou analisados separadamente, especialmente se o objetivo do projeto for identificá-los.

10. Documentação das Conclusões:

É fundamental documentar todas as conclusões e decisões tomadas durante a análise exploratória. Ao remover variáveis ou registros, é importante justificar as escolhas com base em critérios objetivos, como a detecção de outliers ou a presença de multicolinearidade. Essa documentação será valiosa nas próximas etapas do projeto e garante transparência no processo analítico.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.