



Pós-Graduação Data Science Academy

Técnicas e Procedimentos de Pré-Processamento de Dados

Técnicas e Procedimentos de Pré-Processamento de Dados



O pré-processamento de dados envolve uma série de técnicas e procedimentos que ajustam e formatam os dados para atender aos objetivos do projeto, seja para a criação de visualizações, seja para a construção de modelos de Machine Learning. A seguir, destacamos as principais atividades envolvidas nesse processo:

1. Nem Todo Projeto Requer Pré-Processamento Completo:

O pré-processamento dos dados depende dos objetivos do projeto. Em alguns casos, ele pode ser desnecessário ou mínimo, dependendo da forma como os resultados serão entregues e da qualidade dos dados originais.

2. Encoding (Codificação):

A codificação é uma tarefa comum no pré-processamento de dados, especialmente para modelos de Machine Learning que requerem dados numéricos. O encoding converte variáveis categóricas em valores numéricos sem alterar a informação. Essa é uma etapa essencial quando trabalhamos com dados categóricos.

3. Label Encoding:

O label encoding converte variáveis categóricas em números inteiros. Por exemplo, categorias como "A", "B" e "C" são convertidas para 0, 1 e 2, respectivamente. Isso mantém a integridade da informação, enquanto formata os dados para uso em modelos que aceitam apenas entradas numéricas.

4. One-Hot Encoding:

O one-hot encoding cria variáveis dummy para cada categoria de uma variável categórica. Por exemplo, se uma variável "banho" possui as categorias "quente" e "frio", criamos duas variáveis, "banho_quente" e "banho_frio". Cada registro recebe um valor 1 ou 0 dependendo da categoria original. O cuidado necessário aqui é que, quanto maior o número de categorias, maior o número de variáveis resultantes.

5. Divisão em Treino, Teste e Validação:

Para evitar erros no desenvolvimento de modelos de Machine Learning, é fundamental dividir os dados em conjuntos de treino e teste, normalmente em uma proporção de 70/30. Para modelos complexos, como redes neurais, é comum criar um conjunto de validação adicional (70/20/10), usado para verificar o desempenho do modelo durante o treinamento. Isso ajuda a evitar overfitting e garante a capacidade de generalização do modelo.

6. Normalização e Padronização:

Esses processos ajustam a escala dos dados. A normalização coloca os dados em uma faixa específica, como $[0,1]$, enquanto a padronização ajusta os dados para que tenham média 0 e desvio padrão 1. Essas técnicas são essenciais quando os modelos são sensíveis às escalas das variáveis, como redes neurais e algoritmos de distância.

7. Cuidado com o Pré-Processamento Exagerado:

Todas as etapas de pré-processamento precisam ser replicáveis para novos dados que serão usados em modelos treinados. Um pré-processamento excessivo pode complicar o uso do modelo em produção. Aplique apenas o necessário, alterando os dados o mínimo possível para atender aos objetivos do projeto.

8. Redução de Dimensionalidade:


Quando um conjunto de dados contém muitas variáveis (geralmente acima de 30), pode ser necessário reduzir o número de dimensões. A técnica de PCA (Principal Component Analysis) é uma das mais comuns. Ela reduz o número de variáveis preservando a maior parte da informação original. O PCA compacta várias variáveis em um número menor de componentes, mas pode reduzir a interpretabilidade do modelo.

9. Pré-Processamento de Imagens:

Para modelos de Visão Computacional, as imagens precisam ser pré-processadas. Isso envolve padronizar suas dimensões (altura e largura), reduzindo o número de pixels, além de ajustar a escala dos valores dos pixels para uma faixa consistente, facilitando a aplicação dos algoritmos.

10. Pré-Processamento de Texto:

Para trabalhar com dados de texto, é necessário convertê-los em representações numéricas. Duas técnicas comuns são o Bag of Words e o embedding. O Bag of Words conta a frequência de cada palavra no texto, enquanto o embedding cria uma matriz de ocorrências de palavras. É comum remover stopwords (palavras sem relevância como artigos e advérbios) para melhorar a qualidade dos dados de texto.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.