




Pós-Graduação Data Science Academy

Técnicas e Procedimentos de Normalização e Padronização

Técnicas e Procedimentos de Normalização e Padronização



A normalização e a padronização são técnicas amplamente utilizadas no pré-processamento de dados em projetos de Machine Learning e Ciência de Dados. Ambas têm o objetivo de ajustar as variáveis (ou atributos) para que possam ser processadas de maneira eficiente pelos algoritmos, mas cada uma delas é aplicada em situações específicas. A seguir, exploramos as principais características e aplicações de cada técnica.

1. Normalização

A normalização é uma técnica que visa transformar os valores numéricos de um conjunto de dados para uma escala comum, geralmente entre 0 e 1, sem alterar as diferenças proporcionais entre eles. Ela é particularmente útil quando as variáveis possuem intervalos de valores muito diferentes, o que pode causar vieses em algoritmos sensíveis a escalas, como aqueles que utilizam medidas de distância.

Por exemplo, considere um conjunto de dados com duas variáveis: idade e renda. Enquanto a idade varia de 0 a 100, a renda pode variar de 0 a 20.000 ou mais. Essa disparidade nos intervalos faz com que a renda tenha uma influência muito maior nas análises, como em uma regressão linear. Para evitar que uma variável sobreponha a outra apenas devido à sua magnitude, a normalização ajusta os valores para que ambos estejam na mesma escala.

A fórmula da normalização é definida como:

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

Isso resulta em valores entre 0 e 1 (ou entre -1 e 1, se houver valores negativos). A normalização é recomendada para algoritmos como KNN, K-Means e Redes Neurais, especialmente quando os modelos utilizam medidas de distância, como a distância euclidiana.

2. Padronização

A padronização (também conhecida como score Z) transforma os dados de maneira que eles tenham uma distribuição normal, com média 0 e desvio padrão 1. Isso é feito ajustando cada valor de acordo com a fórmula:

$$x' = \frac{x - \mu}{\sigma}$$

Onde:

x' é o valor padronizado,
 μ é a média da variável,
 σ é o desvio padrão da variável.

Essa técnica é ideal para algoritmos que assumem que os dados seguem uma distribuição normal, como SVMs, regressão logística e redes neurais. Ao padronizar os dados, garantimos que cada variável tenha uma influência equivalente no modelo, independentemente de suas escalas originais.

3. Quando Usar Cada Técnica

Normalização é recomendada quando os dados não seguem uma distribuição normal ou quando há variação muito grande nas escalas das variáveis. Algoritmos baseados em distância, como KNN e K-Means, geralmente se beneficiam mais da normalização, pois ela reduz o impacto de variáveis com magnitudes maiores.

Padronização é mais apropriada quando os dados seguem uma distribuição normal ou quando o algoritmo exige que as variáveis tenham uma média de zero e desvio padrão igual a 1. Ela é amplamente utilizada em algoritmos lineares, como regressão logística, SVMs e redes neurais.

4. Considerações sobre Outliers

Ambas as técnicas apresentam desafios quando o conjunto de dados contém outliers. No caso da normalização, os outliers podem comprimir a escala dos outros dados, resultando em uma distribuição distorcida. Já a padronização pode ser mais robusta a outliers, pois não limita os dados a um intervalo fixo, mas ainda assim deve ser aplicada com cautela.

5. Vantagens da Normalização e Padronização


Normalização:

- Ajuda a resolver problemas de convergência em algoritmos sensíveis a escalas.
- Facilita a comparação de variáveis em diferentes escalas, tornando os coeficientes mais interpretáveis.

Padronização:

- Melhora o desempenho de modelos que se beneficiam de uma distribuição normal.
- É particularmente eficaz em melhorar a condição numérica dos problemas de otimização em modelos complexos, como redes neurais profundas.

A escolha entre normalização e padronização depende do tipo de dados e do algoritmo que será utilizado. Ambas as técnicas são essenciais para garantir a qualidade e a eficácia dos modelos de Machine Learning, tornando o treinamento mais eficiente e os resultados mais precisos.

**Equipe DSA**

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.