




Pós-Graduação Data Science Academy

Técnicas e Procedimentos de Machine
Learning (Aprendizado Supervisionado)

Técnicas e Procedimentos de Machine Learning (Aprendizado Supervisionado)



O aprendizado supervisionado é uma das abordagens mais utilizadas em Machine Learning, pois permite que os algoritmos aprendam padrões em dados rotulados para fazer previsões precisas. A seguir, exploramos as principais técnicas e procedimentos envolvidos no aprendizado supervisionado:

1. Dados de Entrada e Saída (Variáveis Preditivas e Alvo):

No aprendizado supervisionado, temos as variáveis preditoras (entrada), que ajudam a explicar a variável alvo (saída). Por exemplo, em um conjunto de dados sobre imóveis, variáveis como o tamanho da casa, número de quartos e localização (bairro) seriam preditoras, enquanto o preço do imóvel seria a variável alvo. O objetivo do modelo é aprender a relação entre essas variáveis de entrada e a variável de saída.

2. Rotulagem dos Dados:

Para aplicar aprendizado supervisionado, os dados precisam estar rotulados, ou seja, precisamos ter tanto os dados de entrada quanto os resultados esperados (a saída). Isso geralmente envolve o uso de dados históricos. No exemplo anterior, precisaríamos de um histórico de várias casas com suas características e respectivos preços. Sem essa rotulagem, o aprendizado supervisionado não pode ser aplicado, pois não teríamos uma referência para treinar o modelo.

3. Identificação de Padrões:

Um ponto importante em Machine Learning é que os algoritmos não criam padrões, mas sim descobrem padrões que já existem nos dados. No exemplo das casas, esperamos que características como o tamanho e o bairro influenciem o preço. No entanto, se não houver uma relação clara entre essas variáveis, o modelo não conseguirá aprender. Se o padrão nos dados

for muito complexo, pode ser necessário reduzir a dimensionalidade para ajudar o modelo a identificá-lo.

4. Regressão (Variável Alvo Quantitativa):

Se a variável alvo for quantitativa (por exemplo, o preço de uma casa, que é uma variável contínua), o aprendizado supervisionado é aplicado para regressão. As variáveis preditoras podem ser numéricas ou categóricas, mas se forem categóricas, técnicas de codificação (encoding) devem ser aplicadas. Além disso, como muitos algoritmos de regressão requerem que os dados estejam na mesma escala, a padronização dos dados pode ser necessária.

5. Classificação (Variável Alvo Qualitativa):

Se a variável alvo for qualitativa (como categorias ou classes), o aprendizado supervisionado é aplicado para classificação. Por exemplo, em um problema onde queremos prever se um e-mail é spam ou não, a variável alvo seria "spam" ou "não spam", e os algoritmos classificariam cada e-mail em uma dessas categorias.

6. Algoritmos e Modelos:

Um algoritmo é a peça de código que aprende a partir dos dados. Quando treinamos um algoritmo com dados rotulados, o resultado é um modelo, que pode ser usado para fazer previsões com novos dados. Cada modelo é ajustado de acordo com o problema que estamos tentando resolver.

7. Modelos Específicos para Problemas Específicos:

Cada modelo é criado para resolver um tipo específico de problema. Um modelo para prever vendas será diferente de um modelo para classificar e-mails como spam ou não. O tipo de problema determina o conjunto de dados, que por sua vez define o algoritmo a ser utilizado na construção do modelo.

8. Escolha do Algoritmo:


Em geral, não sabemos de antemão qual algoritmo será o mais adequado para um determinado problema. O ideal é testar diferentes algoritmos e comparar suas performances para escolher o mais eficiente para o conjunto de dados em questão.

9. Ajuste de Hiperparâmetros:

Cada algoritmo tem seus hiperparâmetros, que controlam sua execução e podem ser ajustados para melhorar o desempenho do modelo. A melhor combinação de hiperparâmetros varia conforme os dados, e é necessário experimentar diferentes combinações para encontrar a mais adequada.

10. Re-Treinamento e Monitoramento Contínuo:

Um modelo precisa ser re-treinado periodicamente com novos dados, pois os padrões nos dados podem mudar ao longo do tempo. Se um modelo começa a apresentar piora em sua performance, isso pode indicar que os padrões mudaram, e o modelo deve ser atualizado. O desempenho de um modelo deve ser monitorado continuamente para garantir que ele permaneça eficaz.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.