



Pós-Graduação Data Science Academy

Técnicas e Procedimentos de Machine Learning (Aprendizado Não Supervisionado)

Técnicas e Procedimentos de Machine Learning (Aprendizado Não Supervisionado)



O aprendizado não supervisionado é uma abordagem de Machine Learning que é utilizada quando não há uma variável alvo claramente definida. O objetivo principal é identificar padrões nos dados com base apenas nas variáveis de entrada. A seguir, detalhamos as principais técnicas e procedimentos relacionados a essa abordagem:

1. Ausência de Variável Alvo:

No aprendizado não supervisionado, trabalhamos apenas com as variáveis de entrada, sem a presença de uma variável alvo. Nessa abordagem, nosso objetivo é agrupar os dados por similaridade, sem a necessidade de prever um resultado específico. Isso difere do aprendizado supervisionado, onde temos uma variável de saída definida que buscamos prever.

2. Detecção de Padrões:

O objetivo do aprendizado não supervisionado continua sendo detectar padrões nos dados, assim como em qualquer técnica de Machine Learning. A diferença é que, nesse caso, os padrões são encontrados apenas entre as variáveis de entrada, sem qualquer relação direta com uma variável alvo. Isso permite a descoberta de insights ocultos e a segmentação de dados de forma autônoma.

3. Algoritmos e Métricas de Avaliação:


Devido à ausência de uma variável alvo, os algoritmos e métricas de avaliação no aprendizado não supervisionado são distintos daqueles usados em aprendizado supervisionado. Avaliar a qualidade dos agrupamentos ou padrões descobertos pode ser mais desafiador, uma vez que não há um resultado "correto" predefinido para comparação. As métricas mais comuns incluem medidas de coesão dentro dos grupos e separação entre os grupos.

4. Uso de Distância Matemática:

A maioria dos algoritmos de aprendizado não supervisionado utiliza distâncias matemáticas para identificar similaridades entre os dados. Um exemplo clássico é o uso de centróides em algoritmos de clustering, como o K-Means. Nesse processo, pontos de dados são atribuídos a grupos com base na proximidade ao centróide mais próximo. A escolha do número de grupos (clusters) é um dos principais hiperparâmetros que podemos ajustar para influenciar os resultados do modelo.

5. Maximização da Separação entre Grupos:

Algoritmos de aprendizado não supervisionado têm como objetivo minimizar as distâncias dentro de cada grupo (cluster) e maximizar as distâncias entre os diferentes grupos. Esse equilíbrio garante que os grupos sejam coesos internamente e distintos entre si, permitindo uma segmentação clara e eficaz dos dados.

**Equipe DSA**

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.