




Pós-Graduação Data Science Academy

Técnicas e Procedimentos de Avaliação de Modelos

Técnicas e Procedimentos de Avaliação de Modelos



Após o treinamento, é fundamental avaliar a performance de um modelo de Machine Learning para garantir sua eficácia. A seguir, exploramos as principais técnicas e procedimentos para avaliar modelos:

1. Importância da Avaliação de Modelos:

Avaliar um modelo é primordial. Sem uma avaliação adequada, um modelo ineficaz pode ser implementado, levando a decisões de negócios equivocadas. Portanto, nunca deixe de avaliar o modelo para garantir que ele atenda aos requisitos de desempenho.

2. Separação de Conjuntos de Treino e Teste:

Não devemos treinar e testar o modelo com o mesmo conjunto de dados. Se fizermos isso, estaremos testando o modelo com dados que ele já viu, o que leva a uma avaliação irrealista. Ao dividir os dados em conjuntos de treino e teste, podemos avaliar o modelo com dados que ele não conhece, o que proporciona uma análise mais verdadeira de sua performance.

3. Validação:

A validação é útil em casos de treinamento longo, como em grandes redes neurais. Embora o teste após o treinamento seja suficiente na maioria dos casos, a validação contínua permite avaliar o desempenho do modelo durante o treinamento, ajudando a identificar problemas de overfitting ou underfitting.

4. Métricas para Aprendizado Supervisionado:

A maior parte das métricas de avaliação são utilizadas em aprendizado supervisionado, já que temos a variável alvo para comparar os resultados. A seguir, abordamos algumas das principais métricas para classificação e regressão.

5. Acurácia:

A acurácia mede o percentual de acertos de um modelo de classificação, ou seja, quantas previsões o modelo acertou em relação ao total de previsões. Embora seja uma métrica global útil, pode ser enganosa em casos de dados desbalanceados. Por exemplo, em um modelo de detecção de fraudes, onde a maioria das transações é legítima, um modelo que classifica todas as transações como legítimas pode alcançar uma acurácia alta, mas falhar em detectar fraudes.

6. Matriz de Confusão:

A matriz de confusão é uma ferramenta que ajuda a entender melhor o desempenho de um modelo de classificação, dividindo as previsões em categorias:

- Verdadeiros Positivos (VP): Classificações corretas da classe positiva.
- Falsos Negativos (FN): Casos onde o modelo previu a classe negativa, mas o valor real era positivo (Erro Tipo II).
- Falsos Positivos (FP): Casos onde o modelo previu a classe positiva, mas o valor real era negativo (Erro Tipo I).
- Verdadeiros Negativos (VN): Classificações corretas da classe negativa.

7. Precisão:

A precisão responde à questão: "Dentre todas as classificações positivas feitas pelo modelo, quantas estão corretas?". É especialmente útil quando os Falsos Positivos são mais prejudiciais que os Falsos Negativos, como em modelos de recomendação de investimentos.

8. Recall (Sensibilidade):

O recall responde à pergunta: "Dentre todos os exemplos positivos reais, quantos o modelo classificou corretamente?". É uma métrica importante quando os Falsos Negativos são mais prejudiciais que os Falsos Positivos, como em modelos de diagnóstico médico.

9. F1-Score:

O F1-Score é a média harmônica entre precisão e recall. Ele é útil quando queremos equilibrar os dois aspectos, sendo uma métrica adequada para cenários em que precisamos ponderar igualmente os Falsos Positivos e os Falsos Negativos.

10. AUC (Area Under The Curve):

A AUC é uma métrica global que mede a área sob a curva ROC (Receiver Operating Characteristic), que compara as taxas de verdadeiros positivos e falsos positivos. Essa métrica é amplamente usada para comparar diferentes modelos de classificação.

11. Coeficiente R^2 (Regressão):

O coeficiente R^2 é uma métrica para modelos de regressão, que mede o quanto da variação dos dados é explicada pelo modelo. Um valor mais próximo de 1 indica que o modelo explica bem os dados, enquanto valores mais baixos indicam que o modelo não está capturando bem as relações entre as variáveis.

12. MAE (Mean Absolute Error):

O erro absoluto médio é uma métrica de regressão que mede a média das diferenças absolutas entre as previsões e os valores reais. Quanto menor o MAE, melhor o desempenho do modelo.

13. MSE (Mean Squared Error):


O erro quadrático médio é outra métrica de regressão que mede a média dos quadrados das diferenças entre as previsões e os valores reais. Por penalizar grandes erros, o MSE é uma métrica útil quando se deseja evitar grandes discrepâncias nas previsões.

14. RMSE (Root Mean Squared Error):

O RMSE é a raiz quadrada do MSE, sendo mais fácil de interpretar. Valores menores de RMSE indicam um modelo com melhor desempenho.

15. Métricas Personalizadas:

É possível criar métricas personalizadas de acordo com as necessidades específicas do projeto, ajustando a fórmula para capturar outros elementos relevantes para a avaliação do modelo.

**Equipe DSA**

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.